



Detección automática de eventos adversos hospitalarios en epicrisis mediante Procesamiento de Lenguaje Natural

Carlos Pérez Pérez
Maestría en Inteligencia Artificial
Universidad Nacional de Ingeniería
Lima, Perú

Resumen—La notificación de eventos adversos en EsSalud depende de un proceso manual y voluntario con un subregistro estimado cercano al 72 %. Este trabajo evalúa un canal de Procesamiento de Lenguaje Natural que detecta eventos adversos en resúmenes de alta y los clasifica según la taxonomía del Anexo 02 de la Directiva GG-ESSALUD-2021, sobre 70,000 epicrisis de MIMIC-IV. El aporte central no es una métrica sino una auditoría: se identificaron y corrigieron siete defectos del canal, entre ellos un confusor de época CIE-9/CIE-10 que producía un caso ejemplar de aprendizaje por atajo, con AUC 0.973 obtenido al reconocer la plantilla de laboratorio de cada periodo en lugar del fenómeno clínico. Tras la corrección, el detector alcanza sensibilidad 0.762 y especificidad 0.770 (AUC 0.843), con un valor predictivo positivo de 0.455 a la prevalencia poblacional (20.12 %). El contraste con transformers clínicos ajustados muestra que el factor determinante no es la arquitectura sino la ventana de contexto: el modelo procesa solo el 9.0 % del documento. La concordancia con un evaluador independiente alcanza $\kappa = 0.644$ (IC 95 % 0.413–0.817), cuyo valor puntual se sitúa en la banda sustancial aunque el límite inferior del intervalo no permite afirmarlo con la muestra disponible.

Index Terms—procesamiento de lenguaje natural, seguridad del paciente, eventos adversos, supervisión débil, MIMIC-IV, aprendizaje por atajo

I. INTRODUCCIÓN

La seguridad del paciente es un eje crítico de la calidad asistencial desde que el informe *To Err Is Human* [28] situó el daño evitable entre las principales causas de mortalidad hospitalaria, y desde que el estudio de Harvard [27] estableció la magnitud del fenómeno mediante revisión manual de historias clínicas. La Organización Mundial de la Salud mantiene la reducción del daño evitable como objetivo prioritario [31].

El problema no es solo la ocurrencia sino la *detección*. Classen *et al.* [29] demostraron que los métodos voluntarios

de notificación subestiman los eventos adversos hasta en un factor de diez frente a la revisión sistemática de historias. En EsSalud la notificación es manual, voluntaria y posterior al hecho: en 2025 se registraron 515 493 egresos hospitalarios [34] y se notificaron 14 275 eventos adversos (2.77 %), muy por debajo del 10 % estimado internacionalmente. La brecha —del orden de 37 000 eventos no notificados en un solo año— delimita el problema que este trabajo aborda.

La detección automática sobre texto clínico libre es una línea establecida: Murff *et al.* [30] identificaron complicaciones posoperatorias en historias electrónicas mediante procesamiento de lenguaje natural, alcanzando sensibilidades muy superiores a la codificación administrativa. Este trabajo se inscribe en esa línea, con dos particularidades: la taxonomía de destino es la normativa peruana [32], [33], y el sistema debe operar sobre resúmenes de alta completos.

La propuesta presentada al curso comprometía cuatro objetivos: construir el corpus mediante supervisión débil con detección de negaciones, comparar un modelo léxico contra transformers clínicos, mapear los eventos al Anexo 02 y validar el resultado con un evaluador independiente mediante el coeficiente κ de Cohen [19]. Los cuatro se ejecutaron y se reportan aquí, incluidos los resultados que refutaron las hipótesis iniciales.

II. ESTADO DEL ARTE

II-A. Detección de eventos adversos en texto clínico

La identificación de eventos adversos ha dependido históricamente de la revisión manual de historias clínicas, método fiable pero inviable a escala: el estudio de Harvard [27] requirió la lectura de más de 30 000 historias. La búsqueda de disparadores —desarrollada por el Institute for Healthcare

Improvement bajo la denominación *Global Trigger Tool*—acotó el volumen a revisar. Aplicándola, Classen *et al.* [29] establecieron que la notificación voluntaria detecta del orden de una décima parte de los eventos que identifica una revisión sistemática. Murff *et al.* [30] dieron el paso al procesamiento automático: aplicando PLN sobre notas clínicas del sistema de veteranos de EE.UU., alcanzaron sensibilidades muy superiores a las de la codificación administrativa para complicaciones posoperatorias. La conclusión transversal de esta línea es que el texto libre contiene información que los códigos administrativos no capturan.

II-B. Modelos de lenguaje aplicados al dominio clínico

La arquitectura Transformer [4] y su materialización en BERT [5] desplazaron a los métodos léxicos en la mayoría de tareas de PLN. En el dominio biomédico surgieron variantes preentrenadas sobre corpus especializados: BioBERT [7] sobre PubMed y PMC, Bio_ClinicalBERT [6] sobre notas clínicas de MIMIC-III, y PubMedBERT [8], que demostró que el preentrenamiento *desde cero* con vocabulario del dominio supera a la adaptación de un modelo general. Huang *et al.* [9] aplicaron esta familia a la predicción de reingreso hospitalario. Para el español existe BETO [10], que habilita la transferencia a la lengua de destino sin traducir el corpus.

II-C. La restricción de la ventana de contexto

Un límite estructural de esta familia de modelos es la ventana de 512 *tokens*, insuficiente para documentos clínicos completos. Beltagy *et al.* [11] y Zaheer *et al.* [12] propusieron mecanismos de atención dispersa que reducen el coste cuadrático y permiten secuencias de hasta 4096 *tokens*. Li *et al.* [13] llevaron esa idea al dominio clínico y mostraron que Clinical-Longformer supera consistentemente a ClinicalBERT en clasificación documental. Esta línea es directamente pertinente para el presente trabajo, como se cuantifica en la Sección VII-C2.

II-D. Supervisión débil y etiquetado programático

La anotación manual de corpus clínicos extensos es prohibitiva. El paradigma de *supervisión débil* formalizado en Snorkel [17] sustituye la anotación por funciones de etiquetado que codifican reglas heurísticas, aceptando ruido a cambio de escala. En texto clínico, el tratamiento de la negación es imprescindible: el algoritmo NegEx [18] sigue siendo la referencia para distinguir la mención de un hallazgo de su afirmación.

II-E. Validez de las mediciones y aprendizaje por atajo

Un cuerpo creciente de literatura advierte que las métricas altas pueden sostenerse en correlaciones espurias. Geirhos *et al.* [25] sistematizaron el fenómeno como *shortcut learning*, y Zech *et al.* [26] documentaron el caso clínico canónico: un detector de neumonía en radiografías que había aprendido a identificar el hospital de procedencia. Esta literatura motiva la auditoría que constituye el aporte central de este trabajo.

II-F. Medición de la fiabilidad entre observadores

Cuando la referencia es un juicio humano, la concordancia se mide con el coeficiente κ de Cohen [19], interpretado según la escala de Landis y Koch [20]. Feinstein y Cicchetti [22] demostraron que con prevalencias extremas el coeficiente se deprime pese a un acuerdo observado alto, y Byrt *et al.* [21] propusieron el PABAK para corregir ese efecto. Sim y Wright [23] sistematizaron los requisitos de tamaño muestral y de reporte del intervalo de confianza, que en este trabajo se estima por *bootstrap* [24].

II-G. Síntesis y brechas de investigación

El estado del arte evidencia tres brechas que este trabajo aborda. Primera: los estudios de detección automática de eventos adversos rara vez auditan la validez de su propia etiqueta, pese a que se construye por reglas sobre codificación administrativa. Segunda: la comparación entre modelos léxicos y transformers clínicos suele reportarse sin controlar la asimetría en la cantidad de texto que cada arquitectura procesa, lo que confunde el efecto del modelo con el de la ventana de contexto. Tercera: las taxonomías empleadas son mayoritariamente anglosajonas, mientras que la aplicación institucional exige la taxonomía normativa local [32], [33], sobre la que casi no existen corpus etiquetados.

III. PROBLEMÁTICA

La notificación de eventos adversos en EsSalud opera de forma reactiva: depende de que un profesional decida reportar, tras el hecho y de manera voluntaria. La consecuencia medible es un subregistro cercano al 72 %, equivalente a unos 37 000 eventos no reportados en un solo año. Esos eventos no solo no se gestionan: son invisibles para la planificación de la calidad, lo que impide priorizar intervenciones, dimensionar el riesgo y anticipar la exposición sancionatoria.

El obstáculo no es la ausencia de información, sino su formato. La descripción de lo ocurrido existe en las epicrisis, redactada en texto libre, pero no en una forma explotable de manera automática. De ahí la pregunta de investigación:

¿Es posible detectar automáticamente, a partir del texto libre de los resúmenes de alta, los eventos adversos ocurridos durante la hospitalización, y clasificarlos según la taxonomía normativa vigente, con una fiabilidad comparable a la del juicio experto?

Responderla exige resolver tres problemas encadenados: construir una etiqueta de referencia sin anotación manual exhaustiva, verificar que el modelo aprende el fenómeno clínico y no un artefacto documental, y demostrar que el criterio aplicado es reproducible por un evaluador independiente.

IV. CORPUS Y MÉTODO

Se emplea MIMIC-IV-Note v2.2 [1], alojada en PhysioNet [3], con 331 793 resúmenes de alta en inglés del Beth Israel Deaconess Medical Center (2008–2019). El corpus de modelado quedó en 70,000 epicrisis (37,692 positivas), techo impuesto por la memoria disponible al vectorizar n -gramas de carácter. La prevalencia poblacional del evento codificado

es 20.12 %: 109,775 hospitalizaciones *con* evento sobre un universo de 545,601 hospitalizaciones registradas en el módulo hospitalario.

El etiquetado sigue el paradigma de **supervisión débil** [17]: reglas sobre códigos diagnósticos y patrones textuales generan etiquetas de forma programática, sin anotación manual exhaustiva. Las negaciones se tratan con el algoritmo NegEx [18], imprescindible en texto clínico donde la mención de una complicación suele aparecer negada (*no evidence of infection*).

La partición se realiza **por paciente** mediante `GroupShuffleSplit` sobre `subject_id`, con verificación explícita de que ningún paciente aparece simultáneamente en entrenamiento y prueba. La vectorización TF-IDF se ajusta únicamente sobre el conjunto de entrenamiento. La implementación emplea `scikit-learn` [14] y la biblioteca *Transformers* [16].

V. VALIDEZ DEL ETIQUETADO Y CONTROL DE SESGOS

El etiquetado por supervisión débil [17] traslada la calidad del corpus a la calidad de las reglas, de modo que su validez debe verificarse de forma explícita y no presuponerse. Se aplicó un protocolo sistemático de control que identificó siete *modos de fallo*, cada uno con su efecto cuantificado sobre el corpus resultante (Tabla I). El procedimiento es reproducible y los modos de fallo son generalizables a cualquier canal de PLN clínico construido sobre reglas.

Tabla I

MODOS DE FALLO DEL ETIQUETADO POR REGLAS Y EFECTO MEDIDO

Defecto	Efecto medido
Muestreo no declarado: se examinaba el 9 % del corpus	301 793 epicrisis sin revisar
<code>re.DOTALL</code> : el comodín cruzaba la epicrisis completa	−63,7 % de detecciones
Códigos CIE-10 con punto frente a MIMIC sin punto	Corpus positivo $\times 267$
Ausencia de clase negativa	Abstención 6/6 ante texto trivial
Confusor de época CIE-9/CIE-10	Ver Secc. V-A
43 de 223 códigos eran reglas muertas (OMS $\neq$ CM)	Medicación $\times 68$
Percentiles degenerados con n pequeño	Inversión de prioridad

La evidencia decisiva del segundo defecto: los patrones que contenían `*` cayeron −84,1 % al acotar su alcance (42 330 a 6 735), mientras que los patrones sin comodín quedaron *idénticos* (13 189 a 13 189). La pérdida provenía del alcance del comodín y no de la especificidad de los patrones.

V-A. El confusor de época: aprendizaje por atajo

El mapeo inicial contenía únicamente códigos CIE-10. Dado que MIMIC-IV abarca 2008–2019, toda hospitalización de la era CIE-9 resultaba negativa *por construcción*: los negativos eran 78.97 % de la era CIE-9 y los positivos 100 % de la era CIE-10.

El clasificador no aprendió a reconocer eventos adversos sino la plantilla de laboratorio de cada época. El rasgo de

mayor peso resultó ser `palabra__rdwsd`, un artefacto de cabecera sin contenido clínico. Es un caso de *shortcut learning* [25]: el modelo explota una correlación espuria disponible en los datos en lugar del fenómeno que se pretende medir, y obtiene métricas excelentes que no generalizan. El paralelo más conocido en el ámbito clínico es el de Zech *et al.* [26], cuyo detector de neumonía en radiografías aprendió a reconocer el hospital de procedencia a partir de marcas en la imagen (Tabla II).

Tabla II

EFECTO DEL CONFUSOR DE ÉPOCA SOBRE LAS MÉTRICAS

Versión	Espec.	AUC	VPP
Inicial (inválida, no se cita)	0.917	0.973	0.433
Reevaluada con emparejamiento	0.694	0.904	0.171
Final, siete defectos corregidos	0.770	0.843	0.455

La corrección consistió en extender el mapeo a CIE-9 (996–999 $\approx$ T80–T88, E870–E879 $\approx$ Y60–Y69, E930–E949 $\approx$ Y40–Y59, 707.0x $\approx$ L89) y en forzar el emparejamiento **a nivel de nota** y no de hospitalización, dado que la cobertura de epicrisis difiere entre eras. El emparejamiento resultante es exacto: 28.92 % frente a 28.92 %. Tras la corrección los rasgos de mayor peso pasaron a ser inequívocamente clínicos (*fall, induced, ileus, revision, in stent, pressure ulcer, restenosis, reaction*) y el artefacto documental desapareció del modelo.

VI. EVALUACIÓN DE LOS MODELOS

La evaluación se diferencia según la etapa del canal y el objetivo de gestión, con métricas elegidas de forma explícita y no por convención.

VI-A. Métricas de la etapa de detección y su justificación

La exactitud global es engañosa en esta tarea: con una prevalencia poblacional del 20.12 %, un clasificador que negara todo evento alcanzaría más del 79 % de aciertos sin detectar un solo caso. Se reportan por tanto métricas sensibles al desbalance:

- **Sensibilidad.** Es la métrica prioritaria desde la perspectiva de gestión: omitir un evento adverso (falso negativo) tiene un coste asistencial y sancionatorio muy superior al de revisar un caso que no lo era.
- **Especificidad.** Controla el volumen de revisión que el sistema impone al servicio de calidad; una especificidad baja lo haría inoperante por saturación.
- **AUC.** Resume la capacidad discriminativa con independencia del umbral, lo que permite comparar modelos sin fijar un punto de operación.
- **Valor predictivo positivo a prevalencia real.** El conjunto de prueba está balanceado por construcción, de modo que su VPP bruto sobreestima el operativo. Se reajusta a la prevalencia poblacional mediante el teorema de Bayes, porque es la cifra que determina cuántas revisiones improductivas generaría el sistema en producción.

Para la clasificación de la naturaleza se prioriza el **F1-macro** sobre el F1-micro: al promediar sin ponderar por frecuencia, penaliza el abandono de las clases minoritarias,

que en seguridad del paciente son precisamente las de mayor gravedad.

VI-B. Protocolo de evaluación y control de fuga

Tres decisiones de protocolo condicionan la validez de las cifras:

1. **Partición por paciente.** Un mismo paciente puede aportar varias notas con vocabulario e historia compartidos. La partición se realiza con `GroupShuffleSplit` agrupando por `subject_id`, con una aserción explícita que verifica la ausencia de solape. Particionar por nota inflaría las métricas.
2. **Ajuste del vectorizador solo en entrenamiento.** El vocabulario y los pesos TF-IDF se estiman exclusivamente sobre el conjunto de entrenamiento.
3. **Intervalos por *bootstrap* agrupado.** Los intervalos de confianza se calculan remuestreando *pacientes* y no notas [24]: con 1.13 veces de ensanchamiento respecto del remuestreo ingenuo, el efecto es moderado pero real, y omitirlo produciría intervalos artificialmente estrechos.

VI-C. Evaluación de la concordancia con criterio humano

Dado que la etiqueta de MIMIC es un estándar de plata, la evaluación se completa con la concordancia frente a un evaluador independiente, medida con el coeficiente κ de Cohen [19] e interpretada según Landis y Koch [20]. Se reporta acompañado del acuerdo observado, del PABAK [21] y de los índices de prevalencia y sesgo, siguiendo la recomendación de Sim y Wright [23] para evitar la interpretación errónea del coeficiente en escenarios desbalanceados [22].

VII. RESULTADOS

VII-A. Detección binaria

Vectorización TF-IDF (palabra y carácter) con LinearSVC balanceado. Los intervalos se calculan por **bootstrap agrupado por paciente**: remuestrear notas sueltas viola la independencia, porque un mismo paciente aporta varias notas al conjunto de prueba (Tabla III).

Tabla III
ETAPA DE DETECCIÓN. IC POR BOOTSTRAP AGRUPADO POR PACIENTE

Métrica	Valor	IC 95 %
Sensibilidad	0.762	[0.751–0.773]
Especificidad	0.770	[0.759–0.781]
AUC	0.843	[0.836–0.849]
VPP (prevalencia real)	0.455	—

El conjunto de prueba está balanceado, por lo que su VPP bruto (0.793) sobreestima el operativo. Se reporta el VPP reajustado a la prevalencia poblacional, que es la cifra con la que trabajaría un servicio de calidad. Ante seis textos triviales o sin contenido clínico el detector se abstuvo en 6 de 6 casos. La Figura effig:roc muestra la curva ROC con el punto de operación empleado y la Figura effig:confusion el reparto de aciertos y errores.




Figura 1. Curva ROC del detector sobre el conjunto de prueba. El punto marcado corresponde al umbral por defecto empleado en operación.

Etiqueta de referencia	Sin evento	5,026	1,502
	Con evento	1,796	5,761
		Sin evento	Con evento
		Predicción del modelo	

Figura 2. Matriz de confusión de la etapa de detección. Los falsos negativos (esquina inferior izquierda) son el error crítico desde la perspectiva de gestión de la seguridad del paciente.

VII-B. Clasificación de la naturaleza y evaluación en cascada

Evaluar la clasificación sobre positivos *de referencia* supone un detector perfecto y sobreestima el rendimiento real. Se reporta por tanto la cascada completa texto → detección → naturaleza (Tabla IV).

Tabla IV
CLASIFICACIÓN AISLADA FRENTE A CASCADA EXTREMO A EXTREMO

Evaluación	F1-micro	F1-macro
Aislada (positivos de referencia)	0.752	0.513
Cascada extremo a extremo	0.493	0.363

La caída es de 34.5 % en F1-micro. Se calculó sobre las 6,655 notas (47.2 % del conjunto de prueba) cuyos pacientes no fueron vistos por *ninguna* de las dos etapas: como cada etapa se particionó por separado, evaluar la cascada sobre todo el conjunto habría constituido fuga de información.

VII-C. Comparación con transformers clínicos

La comparación de mayo concluyó que el modelo léxico superaba al transformer clínico. Al completarla en condiciones controladas, esa conclusión **no se sostiene**: procedía de dos asimetrías no declaradas que favorecían al modelo léxico. Documentarlas importa más que el ranking mismo, porque son errores frecuentes al comparar familias de modelos.

Primera asimetría: la ventana de contexto. La arquitectura BERT [5], [4] limita la entrada a un número fijo de *tokens*. Con la ventana empleada, el transformer accede al 9.0 % del documento —la epicrisis mediana tiene 3,148 *tokens*— mientras que TF-IDF lo procesa íntegro.

Segunda asimetría: la ponderación de clases. El modelo léxico se entrenó con pesos inversamente proporcionales a la frecuencia; el ajuste fino inicial de los transformers empleó entropía cruzada sin ponderar. Dado que el F1-macro penaliza el abandono de las clases minoritarias, esa diferencia de preprocesamiento castiga al transformer en la métrica principal.

Corregidas ambas —añadiendo variantes léxicas sin balanceo y reentrenando Bio_ClinicalBERT con pesos de clase— se obtiene el ranking de la Tabla V, con todos los modelos sobre la misma partición.

La tabla incorpora las variantes léxicas *con* y *sin* ponderación de clases. La distinción no es cosmética: el ajuste fino de los transformers emplea entropía cruzada sin ponderar, de modo que compararlos contra un modelo léxico balanceado atribuiría al modelo una ventaja que procede del preprocesamiento. Las filas «sin balanceo» son las emparejadas.

VII-C1. A igualdad de condiciones, el transformer no queda por debajo: Restringiendo la comparación a los modelos que ven la misma cantidad de texto y emplean ponderación de clases, Bio_ClinicalBERT ajustado alcanza F1-macro 0.354 frente a 0.330 del modelo léxico truncado. La ponderación resulta decisiva para el transformer: sin ella su F1-macro cae a 0.249, una diferencia del 42 % atribuible únicamente al tratamiento del desbalance. La conclusión de que «el modelo simple gana» era, en esa parte, un artefacto del protocolo.

VII-C2. La ventana de contexto sí explica la diferencia real: La arquitectura BERT [5], [4] limita la entrada a un número fijo de *tokens* —512 en su configuración estándar—. Por restricciones de memoria de la GPU disponible, este experimento se ejecutó con una ventana de 256 *tokens*. Dado que las epicrisis del corpus tienen una mediana de 3,148 *tokens*, el transformer accede únicamente al 9.0 % del documento, mientras que TF-IDF lo procesa íntegro. Atribuir la diferencia a la arquitectura sin controlar esa asimetría sería un error de interpretación. Con la ventana estándar de 512 la cobertura seguiría siendo minoritaria (en torno al 16 %), de modo que la conclusión no depende de esta restricción.

Para separar ambos efectos se entrenó el modelo léxico sobre el texto **truncado a la misma ventana**. Su F1-macro cae de 0.391 a 0.275, una pérdida de 0.116 puntos (29.7 % en términos relativos), *con la misma arquitectura y los mismos datos*. Es decir, una fracción sustancial de la desventaja observada en los transformers no proviene del modelo sino de cuánto texto alcanza a leer.




Figura 3. Efecto aislado de la ventana de contexto. Mismo algoritmo y mismos datos; lo único que cambia es cuánto texto procesa el modelo.

El efecto se representa en la Figura *effig:ventana*. Concuere con la literatura sobre documentos clínicos largos: Beltagy *et al.* [11] y Zaheer *et al.* [12] propusieron mecanismos de atención dispersa precisamente para superar ese límite, y Li *et al.* [13] mostraron que extender la ventana de 512 a 4096 *tokens* sobre corpus clínicos supera de forma consistente a ClinicalBERT en clasificación documental. La implicación práctica para este trabajo es directa: la vía de mejora no pasa por un preentrenamiento clínico más específico [8], [9], sino por una arquitectura capaz de abarcar el documento completo.

VII-C3. Vigencia de las cifras previas: Las mediciones de mayo (exactitud 0.731, F1-macro 0.515, κ 0.581 para TF-IDF con LinearSVC) son anteriores a la corrección del sexto defecto, que alteró el reparto de clases. Se conservan por transparencia, pero los valores de la Tabla V, obtenidos todos sobre la misma partición y en la misma ejecución, son los comparables entre sí.

VII-D. Contraste con trabajos previos

La comparación numérica directa con la literatura **no es metodológicamente admisible** en este caso, y conviene argumentar por qué en lugar de forzar una tabla de cifras que induzca a error.

Los trabajos de referencia validan contra *revisión manual de historias clínicas*, que es un estándar de oro; las métricas de este trabajo se calculan contra *códigos CIE*, que constituyen un estándar de plata. Una sensibilidad medida frente a un revisor humano y otra medida frente a una regla de codificación no son la misma magnitud, aunque compartan nombre. Difieren además el corpus, el idioma, el sistema sanitario, la taxonomía de destino y el conjunto de complicaciones consideradas.

Lo que sí puede establecerse es la posición cualitativa del enfoque:

- Murff *et al.* [30] reportan que el procesamiento de lenguaje natural sobre notas clínicas alcanza una **sensibilidad superior y una especificidad inferior** a la de los indicadores de seguridad del paciente derivados de

Tabla V

RANKING DE DESEMPEÑO DE LOS MODELOS EVALUADOS SOBRE LA MISMA PARTICIÓN ESTRATIFICADA (SEMILLA 42), ORDENADO POR F1-MACRO

#	Modelo	Exactitud	F1-macro	κ
1	TF-IDF + LinearSVC (texto completo)	0.715	0.459	0.544
2	TF-IDF + LinearSVC sin balanceo (texto completo)	0.711	0.391	0.513
3	Bio_ClinicalBERT (fine-tuning, ponderado)	0.543	0.354	0.325
4	TF-IDF + LinearSVC (truncado a 1150 car.)	0.575	0.330	0.315
5	TF-IDF + LinearSVC sin balanceo (truncado a 1150 car.)	0.589	0.275	0.295
6	Bio_ClinicalBERT (fine-tuning)	0.607	0.249	0.344
7	BioBERT (fine-tuning)	0.597	0.210	0.318

la codificación al alta. El presente trabajo comparte ese régimen de funcionamiento: sensibilidad y especificidad quedan equilibradas (0.762 y 0.770) y muy por encima de lo que la codificación administrativa alcanza por sí sola, aunque el punto de operación no se optimizó —se mantuvo el umbral por defecto del clasificador—.

- Classen *et al.* [29] establecieron que los métodos basados en notificación voluntaria detectan del orden de **una décima parte** de los eventos que identifica una revisión sistemática. Ese es el margen de subregistro que un sistema automático aspira a cubrir, y el que justifica el enfoque.
- El *Global Trigger Tool* alcanza una detección más completa, pero exige revisión humana de cada caso disparado: no compite en el mismo régimen de coste, sino que define el techo al que un sistema automático se aproxima.

La vía para hacer comparable este trabajo con esa literatura es sustituir el estándar de plata por juicio experto, que es exactamente el objeto de la validación reportada en la sección siguiente.

VIII. VALIDACIÓN CON EVALUADOR INDEPENDIENTE

La propuesta comprometía un segundo evaluador independiente sobre una submuestra, midiendo la concordancia con el coeficiente κ de Cohen. Se ejecutó sobre una muestra ciega estratificada, con una interfaz que oculta el veredicto del sistema, el código diagnóstico de origen y el estrato, y con registro automático del tiempo dedicado a cada caso.

Protocolo de lectura. Ambos evaluadores dispusieron de la *epicrisis completa*. La interfaz presenta en primer plano las secciones de evolución hospitalaria y diagnósticos al alta —donde la norma documental de MIMIC sitúa las complicaciones— y mantiene el texto íntegro accesible de forma inmediata. La presentación sigue una regla estructural fija, idéntica para todos los casos e independiente del veredicto del sistema, de modo que no introduce sesgo hacia la predicción del modelo. El manual de anotación exige además *cita literal* del fragmento que sustenta todo veredicto positivo, lo que obliga a recurrir al texto completo cuando el resumen inicial no basta. Todas las anotaciones se realizaron aplicando el manual reconciliado con la directiva institucional; una fase piloto previa, anterior a la existencia de dicho manual, se trató por separado y no se integró en el cálculo de concordancia.

Sobre 78 casos doble-anotados el acuerdo observado es 0.872 y el coeficiente $\kappa = 0.644$ (IC 95 % 0.413–0.817),

situado en la banda *sustancial* de Landis y Koch. El límite inferior del intervalo queda por debajo del umbral de 0.61 por efecto del tamaño muestral, por lo que la afirmación se enuncia con esa reserva. El índice de prevalencia es 0.538: con clases tan desbalanceadas el coeficiente se deprime (paradoja de Feinstein–Cicchetti), razón por la cual se reporta junto al PABAK (0.744) y al acuerdo observado. La prueba de McNemar no detecta sesgo sistemático entre evaluadores ($p = 0.34$).

VIII-A. Concordancia en la naturaleza del evento

Sobre los casos en que ambos evaluadores coincidieron en la existencia del evento ($n = 55$), la concordancia en su *naturaleza* resulta $\kappa = 0.281$ (IC 95 % 0.029–0.654), con un acuerdo exacto de 0.855.

Este coeficiente **no es interpretable** en la presente muestra, y se reporta precisamente para dejar constancia de ello. La discrepancia entre un acuerdo observado alto y un κ bajo obedece a la concentración extrema de la variable: la muestra de validación está restringida a eventos de infección por construcción, de modo que casi todos los casos comparten una misma naturaleza y el acuerdo esperado por azar se aproxima a la unidad. Es la paradoja descrita por Feinstein y Cicchetti [22] llevada al límite. Estimar la concordancia en naturaleza exigiría una muestra estratificada sobre las doce categorías, no sobre el veredicto binario.

IX. CLASIFICACIÓN DEL CORPUS ERSF EN ESPAÑOL CON ETIQUETA DE ORO

IX-A. Motivación: estándar de plata frente a estándar de oro

Las etiquetas del corpus MIMIC se derivan de codificación administrativa CIE: el modelo aprende a predecir códigos, no juicios clínicos, y constituyen por tanto un *estándar de plata*. Toda métrica de las secciones anteriores hereda esa limitación.

Para contrastar el enfoque contra criterio humano se incorporó un segundo corpus, en español y sobre la taxonomía peruana: 8,799 ocurrencias notificadas al sistema institucional de reporte de eventos adversos, en las que profesionales expertos —con formación en gestión de la calidad, seguridad del paciente y auditoría médica— leyeron la descripción textual y codificaron, una a una, el tipo de evento, la naturaleza según el Anexo 02 y la severidad según el Anexo 03. Es un *estándar de oro*: juicio humano especializado, en el idioma y bajo la norma de destino del sistema.

IX-B. Preprocesamiento

El texto libre exigió tres correcciones antes de modelar:

- **Anonimización.** Las columnas no contenían identificadores, pero la narrativa sí: se retiraron 124 secuencias numéricas compatibles con documentos de identidad, además de nombres propios asociados, iniciales e instituciones nombradas, sustituidos por marcadores. Los casos que no admitían regla automática sin riesgo de borrar vocabulario clínico se marcaron para revisión humana en lugar de silenciarse.
- **Deduplicación.** 2,463 registros resultaron duplicados o demasiado breves; el corpus quedó en 6,336 textos únicos. Sin este paso el mismo texto aparecía en entrenamiento y prueba, inflando artificialmente las métricas.
- **Normalización de etiquetas** y descarte de las clases con menos de 50 ejemplos, declaradas no modelables.

Se aplicó partición estratificada 80/20 con verificación explícita de que ningún texto aparece en ambos conjuntos, y vectorización TF-IDF de unigramas y bigramas con supresión de acentos.

IX-C. Tareas y resultados

El corpus permite tres tareas que el corpus MIMIC no puede sostener (Tabla VI).

Tabla VI
TAREAS DE CLASIFICACIÓN SOBRE EL CORPUS ERSP (ETIQUETA DE ORO)

Tarea	n	Cl.	Modelo	F1-mac.	F1-mic.
Binaria	6,334	2	LogReg	0.860	0.864
Naturaleza	6,276	9	LinearSVC	0.767	0.845
Severidad	6,279	4	LogReg	0.606	0.725

Tarea 1: evento adverso frente a incidente. Es la distinción central de la norma —si hubo o no daño al paciente— y *no puede medirse sobre MIMIC*, porque un resumen de alta no documenta los cuasi-incidentes. El corpus ERSP sí los contiene, con clases casi balanceadas, y la tarea alcanza F1-macro 0.860. Es la primera evidencia del trabajo de que el criterio nuclear del codebook es aprendible automáticamente.

Tarea 2: naturaleza del evento. Es la tarea homóloga a la Sección V-A pero con etiqueta humana. Nueve de las doce naturalezas superan el umbral de 50 ejemplos, cubriendo el 99.1 % de los registros. El desglose por clase (Tabla VII) muestra un resultado relevante para la tesis: *Gestión de la organización*, que en MIMIC era inviable por escasez de casos, alcanza aquí F1 0.853 con 1 431 ejemplos de entrenamiento. El corpus en español rescata clases que el corpus en inglés no cubre.

Tarea 3: severidad. Sigue la escala del Anexo 03 y alimenta la valoración de impacto de la matriz de priorización institucional. El rendimiento global es menor y decae de forma monótona con la gravedad. El desglose por clase que sigue corresponde a **LinearSVC** (F1-macro 0.553), y no al mejor modelo de la Tabla VI: se explicita para que las cifras sean

Tabla VII
NATURALEZA DEL EVENTO: DESGLOSE POR CLASE (LINEARSVC)

Naturaleza (Anexo 02)	n prueba	F1
Cuidado del paciente	454	0.923
Gestión de la organización	286	0.853
Medicación	147	0.875
Dispositivo médico / equipo / bien	134	0.707
Infección asociada a la atención	58	0.879
Insumos	56	0.679
Procedimiento	44	0.595
Historia clínica	42	0.854
Comportamiento	35	0.542

Tabla VIII
SEVERIDAD (ANEXO 03): DESGLOSE POR CLASE CON LINEARSVC

Nivel de severidad	n prueba	F1
No causó daño	521	0.836
Leve	491	0.723
Moderado	221	0.506
Grave	23	0.148

reconciliables, ya que el promedio no ponderado de los valores por clase debe reproducir exactamente el F1-macro declarado.

El patrón es esperable —las clases graves son minoritarias— pero tiene una consecuencia práctica que conviene declarar: el sistema es notablemente más fiable descartando daño que graduándolo, de modo que la severidad debería asistir al evaluador humano y no sustituirlo.




Figura 4. Desempeño por naturaleza del evento sobre el corpus en español con etiqueta de oro. El número de casos de prueba acompaña a cada clase: las de menor F1 son también las de menor soporte.

IX-D. Discusión

El desglose completo se representa en la Figura effig:ersp. Las clases con peor desempeño son *Comportamiento* (F1 0.542), *Procedimiento* (0.595) e *Insumos* (0.679), las tres con menos de 60 casos de prueba: el limitante es el número de ejemplos, no el método.

Estas cifras **no** son comparables con las de la Tabla IV, y conviene ser explícito para evitar una lectura errónea. El texto ERSP son descripciones breves —unos 120 caracteres—

redactadas por alguien que *ya identificó* el evento y lo está notificando; la epicrisis son unos 17 500 caracteres en los que el evento debe *localizarse* entre el resto de la historia. La tarea del ERSP es más sencilla por construcción, y su mejor rendimiento no indica un modelo superior sino un problema distinto.

Lo que sí demuestran es doble: que la taxonomía nacional es aprendible con etiqueta humana experta, y que existe una vía de transferencia del sistema al español que no depende de traducir el corpus en inglés.

X. DE LA DETECCIÓN A LA GESTIÓN: PRIORIZACIÓN Y RESPONSABLE

Detectar y clasificar un evento no lo gestiona. Un servicio de calidad que recibiera varios miles de detecciones anuales sin criterio de ordenación quedaría igual de inoperante que con el subregistro actual. El canal se completa por tanto con dos etapas que traducen la salida del clasificador en una decisión de gestión: **priorizar** y **asignar responsable**.

X-A. Operacionalización de la matriz de priorización

La priorización no emplea un criterio propio sino el instrumento normativo vigente: la *Matriz de Priorización de Impactos en Salud*, que la Directiva N.º 7-OGCyH-ESSALUD-2020 cita en su artículo 5.13 como herramienta de gestión. Esto sitúa el aporte del trabajo en el lugar correcto: no propone una métrica de prioridad, sino que *automatiza el cálculo* de una que la institución ya reconoce.

Para cada tipo de evento i se calculan cinco magnitudes:

$$A_i = \text{frecuencia observada} \quad (1)$$

$$B_i = \frac{A_i}{\sum_j A_j} \times 9 \quad (2)$$

$$G_i = 0,40 c_i + 0,20 d_i + 0,15 e_i + 0,25 f_i \quad (3)$$

$$H_i = B_i \times G_i \quad I_i = \frac{H_i}{\sum_j H_j} \quad J_i = I_i \times 100 \quad (4)$$

donde c es la prolongación de estancia, d las complicaciones intrahospitalarias, e los sobrecostos por no calidad y f la insatisfacción e imagen institucional, valoradas en la escala ordinal del instrumento (muy alto 9, alto 6, medio 3, bajo 1, nulo 0). B traslada la frecuencia relativa a la escala de nueve puntos; G pondera el impacto; J expresa la prioridad como porcentaje del impacto total.

Las tres primeras dimensiones son derivables de MIMIC-IV: la prolongación de estancia se obtiene de las fechas de ingreso y alta, las complicaciones de los propios eventos detectados y los sobrecostos como proxy de la estancia y los procedimientos adicionales. La cuarta —insatisfacción— no tiene correlato en el registro clínico y requiere valoración institucional, lo que constituye una limitación declarada del despliegue automático.

X-B. Bandas de prioridad y una degeneración corregida

Las bandas se establecen sobre J por percentiles: verde por debajo de P_{25} , amarillo hasta P_{75} y rojo por encima. Este

criterio, correcto con carteras amplias de eventos, **se degenera con pocos eventos distintos**: los percentiles se comprimen y llegan a invertir la prioridad. En pruebas con $n < 8$ se observó que una úlcera por presión de impacto $G = 6,3$ quedaba clasificada en verde mientras un evento de $G = 2,3$ resultaba rojo.

La implementación incorpora una salvaguarda: por debajo de ocho eventos distintos abandona los percentiles y aplica un corte absoluto sobre el impacto ($G \geq 6$ rojo, $G \geq 3$ amarillo). Verificado sobre el mismo caso, la úlcera pasa a rojo y el evento menor a verde. El criterio empleado se registra junto al resultado, de modo que toda priorización declara cómo se obtuvo.

X-C. Asignación del responsable

El último eslabón traduce la banda en un nivel de la pirámide de gestión, que es lo que convierte un hallazgo en una acción con destinatario (Tabla IX).

Tabla IX
ASIGNACIÓN DE RESPONSABLE SEGÚN BANDA DE PRIORIDAD

Banda	Nivel de gestión responsable
Verde	Nivel I: áreas operativas y servicios de salud
Amarillo	Nivel II: departamentos a cargo de los procesos transversales de las cadenas de valor
Rojo	Nivel III: varios departamentos, bajo liderazgo de la máxima autoridad del establecimiento

La lógica es de escalamiento: un evento aislado de bajo impacto se resuelve donde ocurre, mientras que uno de alta prioridad involucra procesos transversales y exige conducción institucional. La asignación es determinista y auditable —no interviene ningún modelo—, lo que resulta deseable en un componente que reparte responsabilidad.

X-D. Clasificación según la jerarquía normativa

En paralelo, cada detección se clasifica según el artículo 5 de la Directiva: *incidente* cuando no hubo daño, *evento adverso* cuando lo hubo, y *evento centinela* ante muerte o daño permanente que exija tratamiento permanente.

Dos precisiones sobre el alcance en MIMIC-IV. El **incidente queda fuera de alcance**: por definición no causa daño y un resumen de alta no documenta cuasi-fallas, que solo existen en un sistema de notificación voluntaria. El **evento centinela sí es detectable** a partir del desenlace registrado —mortalidad hospitalaria, destino al alta, traqueostomía o diálisis de novo— y es la categoría de mayor valor para un tablero de gestión, porque concentra los casos que exigen investigación obligatoria.

X-E. Estado de la integración

Las tres etapas están implementadas y verificadas de forma independiente. El presente informe reporta con detalle la primera (detección y clasificación) por ser la que constituye el objeto del curso; la evaluación cuantitativa *de extremo a extremo* de la cadena completa —incluyendo el acuerdo

entre la prioridad calculada y la que asignaría un comité de calidad— permanece pendiente y se declara como tal.

XI. LIMITACIONES

1. **Estándar de plata.** Las métricas sobre MIMIC miden acuerdo con etiquetas derivadas de códigos CIE y no con juicio clínico; un falso positivo puede ser la detección correcta de un evento no codificado.
2. **Reutilización del conjunto de prueba.** La misma partición se evaluó a lo largo de las sucesivas iteraciones, lo que introduce un sesgo optimista no cuantificado. El umbral de decisión no se ajustó.
3. **Alcance de la validación experta.** La muestra de revisión está restringida a eventos de infección, de modo que κ y el VPP corregido se enuncian sobre ese subconjunto.
4. **Cobertura de datos estructurados.** Las tablas de cuidados intensivos cubren el 19.7 % de las epicrisis, lo que limita cualquier regla basada en signos vitales.
5. **Independencia del anotador.** El autor es a la vez desarrollador del modelo y anotador de referencia. Se mitiga con interfaz ciega, orden aleatorio, registro automático del tiempo por caso y estimación de la fiabilidad contra un evaluador independiente.

XII. CONCLUSIONES

El resultado con mayor valor de este trabajo es negativo y se dirige contra su propia versión anterior: la conclusión de que un modelo léxico superaba a los transformers clínicos **no resistió el control de las condiciones de comparación**. Dos asimetrías no declaradas —la ventana de contexto y la ponderación de clases— explicaban la ventaja atribuida al modelo simple. A igualdad de ambas, el transformer ajustado no queda por debajo.

Lo que sí resiste es el efecto de la **ventana de contexto**: truncar el texto a lo que el transformer alcanza a leer degrada al propio modelo léxico con la misma arquitectura y los mismos datos. Dado que el modelo accede al 9.0 % de la epicrisis, la vía de mejora es una arquitectura de secuencia larga [13], [11] y no un preentrenamiento clínico más específico.

En el plano metodológico, el aporte central es la **auditoría de validez del etiquetado**: siete modos de fallo con efecto cuantificado, y el confusor de época como caso ejemplar de aprendizaje por atajo —un AUC de 0.973 sostenido en el reconocimiento de una plantilla documental— que la corrección redujo a 0.843 sobre una señal genuinamente clínica.

La **evaluación en cascada** muestra que reportar la clasificación aislada sobreestima el rendimiento operativo en 34 %. La **validación con un evaluador independiente** sitúa el valor puntual de la concordancia en la banda sustancial, con la reserva del tamaño muestral. El **corpus en español con etiqueta de oro** abre la transferencia a la taxonomía nacional, y la **integración con la matriz de priorización** (Sección X) convierte la detección en una decisión de gestión con responsable asignado, que es el destino aplicado del sistema.

REFERENCIAS

- [1] A. E. W. Johnson, L. Bulgarelli, L. Shen, *et al.*, “MIMIC-IV, a freely accessible electronic health record dataset,” *Scientific Data*, vol. 10, art. 1, 2023.
- [2] A. E. W. Johnson, T. J. Pollard, L. Shen, *et al.*, “MIMIC-III, a freely accessible critical care database,” *Scientific Data*, vol. 3, art. 160035, 2016.
- [3] A. L. Goldberger, L. A. N. Amaral, L. Glass, *et al.*, “PhysioBank, PhysioToolkit, and PhysioNet,” *Circulation*, vol. 101, no. 23, pp. e215–e220, 2000.
- [4] A. Vaswani, N. Shazeer, N. Parmar, *et al.*, “Attention is all you need,” en *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [5] J. Devlin, M.-W. Chang, K. Lee y K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding,” en *Proc. NAACL-HLT*, 2019, pp. 4171–4186.
- [6] E. Alsentzer, J. Murphy, W. Boag, *et al.*, “Publicly available clinical BERT embeddings,” en *Proc. 2nd Clinical Natural Language Processing Workshop*, NAACL, 2019, pp. 72–78.
- [7] J. Lee, W. Yoon, S. Kim, *et al.*, “BioBERT: a pre-trained biomedical language representation model for biomedical text mining,” *Bioinformatics*, vol. 36, no. 4, pp. 1234–1240, 2020.
- [8] Y. Gu, R. Tinn, H. Cheng, *et al.*, “Domain-specific language model pretraining for biomedical natural language processing,” *ACM Trans. Computing for Healthcare*, vol. 3, no. 1, pp. 1–23, 2021.
- [9] K. Huang, J. Altsaier y R. Ranganath, “ClinicalBERT: Modeling clinical notes and predicting hospital readmission,” *arXiv:1904.05342*, 2019.
- [10] J. Cañete, G. Chaperon, R. Fuentes, *et al.*, “Spanish pre-trained BERT model and evaluation data,” en *PML4DC at ICLR*, 2020.
- [11] I. Beltagy, M. E. Peters y A. Cohan, “Longformer: The long-document transformer,” *arXiv:2004.05150*, 2020.
- [12] M. Zaheer, G. Guruganesh, A. Dubey, *et al.*, “Big Bird: Transformers for longer sequences,” en *NeurIPS*, 2020.
- [13] Y. Li, R. M. Wehbe, F. S. Ahmad, H. Wang y Y. Luo, “Clinical-Longformer and Clinical-BigBird: Transformers for long clinical sequences,” *arXiv:2201.11838*, 2022.
- [14] F. Pedregosa, G. Varoquaux, A. Gramfort, *et al.*, “Scikit-learn: Machine learning in Python,” *J. Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [15] A. Joulin, E. Grave, P. Bojanowski y T. Mikolov, “Bag of tricks for efficient text classification,” en *Proc. EACL*, 2017, pp. 427–431.
- [16] T. Wolf, L. Debut, V. Sanh, *et al.*, “Transformers: State-of-the-art natural language processing,” en *Proc. EMNLP: System Demonstrations*, 2020, pp. 38–45.
- [17] A. Ratner, S. H. Bach, H. Ehrenberg, *et al.*, “Snorkel: Rapid training data creation with weak supervision,” *Proc. VLDB Endowment*, vol. 11, no. 3, pp. 269–282, 2017.
- [18] W. W. Chapman, W. Bridewell, P. Hanbury, G. F. Cooper y B. G. Buchanan, “A simple algorithm for identifying negated findings and diseases in discharge summaries,” *J. Biomedical Informatics*, vol. 34, no. 5, pp. 301–310, 2001.
- [19] J. Cohen, “A coefficient of agreement for nominal scales,” *Educational and Psychological Measurement*, vol. 20, no. 1, pp. 37–46, 1960.
- [20] J. R. Landis y G. G. Koch, “The measurement of observer agreement for categorical data,” *Biometrics*, vol. 33, no. 1, pp. 159–174, 1977.
- [21] T. Byrt, J. Bishop y J. B. Carlin, “Bias, prevalence and kappa,” *J. Clinical Epidemiology*, vol. 46, no. 5, pp. 423–429, 1993.
- [22] A. R. Feinstein y D. V. Cicchetti, “High agreement but low kappa: I. The problems of two paradoxes,” *J. Clinical Epidemiology*, vol. 43, no. 6, pp. 543–549, 1990.
- [23] J. Sim y C. C. Wright, “The kappa statistic in reliability studies: use, interpretation, and sample size requirements,” *Physical Therapy*, vol. 85, no. 3, pp. 257–268, 2005.
- [24] B. Efron y R. J. Tibshirani, *An Introduction to the Bootstrap*. Nueva York: Chapman & Hall, 1993.
- [25] R. Geirhos, J.-H. Jacobsen, C. Michaelis, *et al.*, “Shortcut learning in deep neural networks,” *Nature Machine Intelligence*, vol. 2, pp. 665–673, 2020.
- [26] J. R. Zech, M. A. Badgeley, M. Liu, *et al.*, “Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: A cross-sectional study,” *PLoS Medicine*, vol. 15, no. 11, e1002683, 2018.

- [27] T. A. Brennan, L. L. Leape, N. M. Laird, *et al.*, “Incidence of adverse events and negligence in hospitalized patients,” *New England J. Medicine*, vol. 324, no. 6, pp. 370–376, 1991.
- [28] L. T. Kohn, J. M. Corrigan y M. S. Donaldson (eds.), *To Err Is Human: Building a Safer Health System*. Washington, DC: National Academies Press, 2000.
- [29] D. C. Classen, R. Resar, F. Griffin, *et al.*, “Global Trigger Tool shows that adverse events in hospitals may be ten times greater than previously measured,” *Health Affairs*, vol. 30, no. 4, pp. 581–589, 2011.
- [30] H. J. Murff, F. FitzHenry, M. E. Matheny, *et al.*, “Automated identification of postoperative complications within an electronic medical record using natural language processing,” *JAMA*, vol. 306, no. 8, pp. 848–855, 2011.
- [31] World Health Organization, *Global Patient Safety Action Plan 2021–2030: Towards eliminating avoidable harm in health care*. Ginebra: WHO, 2021.
- [32] EsSalud, *Directiva de Eventos Adversos*, GG-ESSALUD-2021, Anexo 02: taxonomía de eventos adversos; Anexo 03: escala de severidad.
- [33] EsSalud, *Directiva N.º 7-OGCyH-ESSALUD-2020: gestión del reporte de eventos adversos y seguridad del paciente*.
- [34] EsSalud, *EsSalud en Cifras: Informativo Mensual*, edición definitiva de diciembre de 2025, publicada el 26 de marzo de 2026. Estadística Institucional. [En línea]. Disponible en: <https://www.gob.pe/institucion/essalud/informes-publicaciones/6505357-essalud-en-cifras-informativo-mensual-2025>