

Detección automática de eventos adversos hospitalarios en notas clínicas

Un canal de Procesamiento de Lenguaje Natural sobre MIMIC-IV, auditado y validado contra juicio experto

Curso **MIA-10 · Procesamiento del Lenguaje Natural**

Docente **Dr. Wester Zela Moraya**

Autor **Carlos Pérez Pérez**

Fecha 9 de agosto de 2026

EL TRABAJO EN CUATRO CIFRAS

70,000 notas clínicas procesadas

33 h 54 min de cómputo registrado

7 modelos comparados

0.843 AUC del detector final

Agenda

1

Introducción

Seguridad del paciente y la norma

2

Planteamiento del problema

El subregistro del 72 %

3

Antecedentes

Estado del arte y selección del modelo

4

Planteamiento de la solución

Datos · Preprocesamiento · Modelamiento · Ejecución · Resultados

5

Conclusiones

Qué se confirmó y qué se refutó

6

Recomendaciones

Hacia dónde sigue el trabajo

7

Referencias

34 fuentes citadas

El punto 4 concentra el 60 % de la exposición e incluye la ejecución real del código: comandos, salidas de consola y el cuaderno corriendo en vivo.

Un daño causado por la atención, no por la enfermedad

- **Definición.** Daño no intencional derivado de la atención sanitaria, no del curso natural de la enfermedad del paciente.
- **Magnitud.** Están entre las 10 primeras causas de muerte y discapacidad en el mundo (OMS).
- **En el Perú.** La Directiva GG-ESSALUD-2021 los regula y define su notificación obligatoria.

ANEXO 02 · LA TAXONOMÍA QUE SE AUTOMATIZA

231	eventos adversos tipificados
12	naturalezas que los agrupan
4	niveles de severidad (Anexo 03)

La tarea de este trabajo: leer el texto libre de una nota clínica y decidir si contiene un evento adverso y de qué naturaleza es, según esa taxonomía.

La información existe, pero nadie la lee

~72 %

de los eventos adversos no se notifican en EsSalud

unos 37,000 al año

100 %

de las notas clínicas contienen esa información en texto libre

no explotable a mano

Manual

la notificación depende de que alguien decida reportar

y voluntaria

Por qué falla el registro manual

- Subnotificación por temor a la sanción
- Saturación del personal: el evento se registra pero no se analiza
- Priorización heterogénea entre servicios y lenta
- El texto clínico es largo (mediana 3,148 tokens)
- El evento no está señalado: hay que encontrarlo
- Sin denominador no se puede priorizar por riesgo

Pregunta de investigación: ¿es posible detectar automáticamente, desde el texto libre del resumen de alta, los eventos adversos ocurridos durante la hospitalización, y clasificarlos según la taxonomía normativa, con fiabilidad comparable a la del juicio experto?

Objetivos del trabajo

Objetivo general — diseñar, implementar y validar un canal de PLN que detecte y priorice eventos adversos automáticamente, con miras a su transferencia a EsSalud.

Objetivo específico		Estado al día de hoy
OE1	Construir un corpus etiquetado por supervisión débil	Cumplido · 70,000 notas clínicas
OE2	Comparar transformers biomédicos con modelos clásicos	Cumplido · 7 modelos
OE3	Automatizar la matriz de priorización GEMSES	Implementado · fuera del alcance de PLN
OE4	Contrastar el sistema contra evaluadores expertos	Cumplido · 163 casos con juicio experto
OE5	Documentar la transferencia al español	Cumplido · 6,336 casos ERSP

Esta exposición se concentra en OE1, OE2, OE4 y OE5, que son los objetivos de procesamiento de lenguaje natural. El OE3 es gestión y se muestra solo como destino aplicado.

Estado del arte: cinco líneas que sostienen el diseño

Línea	Referencia	Qué aporta a este trabajo
Supervisión débil	Ratner et al. (Snorkel)	Etiquetar a escala con reglas, sin anotación manual masiva
Aprendizaje por atajo	Geirhos et al. (2020); Zech et al. (2018)	Un modelo puede acertar por la razón equivocada: hay que auditarlo
Ventana de contexto	Li et al. (2022) · Clinical-Longformer	Extender la ventana a 4,096 supera a ClinicalBERT en texto largo
Encoders clínicos ES	JAMIA (2024) · BETO, bsc-bio-ehr-es	Fija la expectativa realista para la transferencia al español
Fiabilidad observador	Byrt et al. (1993) · PABAK	Corrige la paradoja de kappa cuando la prevalencia es desigual

Zech et al. entrenaron un detector de neumonía que aprendió a reconocer el hospital de procedencia por marcas en la radiografía. Ese antecedente es exactamente lo que encontramos aquí — y lo veremos medido.

Cómo se eligió el modelo, y con qué criterio

La tarea determina la métrica, y la métrica determina qué ranking es pertinente. No al revés.

Instrumento	Por qué se usó o se descartó
MTEB / MMTEB Leaderboard	Único ranking masivo que puntúa clasificación y filtra por idioma
IberBench (arXiv 2504.16921)	Referencia para español; mide tareas de interés industrial
JAMIA 2024 — encoders clínicos ES	Evidencia revisada por pares sobre 12 corpus clínicos
Open LLM Leaderboard	DESCARTADO: archivado por sus autores y mide razonamiento, no clasificación


FILTROS DUROS DE ADMISIBILIDAD

- **F1** clasificación multietiqueta
- **F2** opera sobre inglés clínico
- **F3** CPU, huella ≤ 2.5 GB
- **F4** cumple el DUA de PhysioNet
- **F5** pesos y código libres


El filtro F4 es el que casi nadie aplica: PhysioNet prohíbe expresamente enviar texto de MIMIC a APIs de terceros. Eso elimina de entrada a ChatGPT y a cualquier LLM por API pública.

El flujo completo, de la nota libre al responsable


1 · CONSTRUCCIÓN DEL CORPUS



2 · MODELADO Y VALIDACIÓN



3 · TRANSFERENCIA Y DESTINO



Las fases del flujo y el script que ejecuta cada una

Fase	Qué resuelve	Script
3	Corpus por supervisión débil: códigos CIE + 35 patrones	fase3_v2_corpus_completo.py
4	Comparación de modelos, fuga, circularidad, multietiqueta	fase4_*.py (7 scripts)
9	Modelo final con el confusor de época controlado	fase9_modelo_final.py
11	Ajuste fino de Bio_ClinicalBERT y BioBERT en GPU	fase11_finetuning_transformers.py
12	Contraste contra el consenso de dos expertos	fase12_sistema_vs_experto.py
OE5	Transferencia al español con etiqueta de oro	oe5_ersp_preparar.py

Todo el código es público en github.com/carlosperez100/PLN_SP; los datos clínicos NO se versionan (DUA de PhysioNet y protección de datos). La bitácora conserva el comando y la salida de consola de cada corrida.

Los datos: MIMIC-IV-Note v2.2

331,793 resúmenes de alta del Beth Israel Deaconess Medical Center (2008–2019), con acceso credencializado por PhysioNet.

70,000

notas clínicas en el corpus de modelado

37,692

positivas (53.8% del corpus)

20.12%

prevalencia POBLACIONAL real

109,775

hospitalizaciones con evento

Por qué 70,000 y no las 331,793

Vectorizar n-gramas de carácter sobre más de 100,000 notas desborda la RAM disponible. El techo práctico verificado fue de 70,000 notas. El corpus está balanceado a propósito; la población no lo está.

CONTROL DEL CONFUSOR DE ÉPOCA

positivos era CIE-10: 28.92%

negativos era CIE-10: 28.92%

diferencia: 0.0000%

La prevalencia poblacional (20.12 %) es muy distinta de la del conjunto de prueba, que está balanceado. Esa diferencia es la que obliga a reajustar el valor predictivo positivo — lo veremos en resultados.

Segundo corpus: texto peruano real, con etiqueta de oro

8,799 ocurrencias REALES del sistema peruano de reporte, en español, codificadas una a una por profesionales contra los Anexos 02 y 03. No es una simulación ni una traducción: es la norma y el idioma de destino.

Paso del preprocesamiento	Casos
Registros originales	8,799
Identificadores anonimizados en el texto	124
Textos demasiado breves (< 30 caracteres)	640
Duplicados eliminados	2,463
Corpus final	6,336

ESTÁNDAR DE PLATA FRENTE A ESTÁNDAR DE ORO

MIMIC se etiqueta con códigos CIE que asigna un codificador administrativo: estándar de PLATA.

El ERSP lo codificó un profesional leyendo cada descripción contra la norma: estándar de ORO. Es la primera medición contra criterio humano.

Sin la deduplicación el mismo texto caía en entrenamiento y en prueba, y las métricas salían infladas. Ese paso solo eliminó 2,463 filas de 8,799.

Advertencia de comparabilidad — estas cifras NO son comparables con las de MIMIC: el reporte ERSP describe un evento que quien lo escribió YA identificó; en la nota clínica el evento hay que ENCONTRARLO. Es un problema distinto y más fácil por construcción.

Preprocesamiento (1): etiquetar 331,793 notas sin anotarlas a mano

fase3_v2_tier_a_corregido.py · fase3_v2_corpus_completo.py

```
# Tier A - los codigos CIE-10 del Anexo 02 llevan punto (A04.7)
# y MIMIC los guarda sin punto (A047). El JOIN nunca acertaba.
clave = orig.replace('.', '').upper()          # <-- EL ARREGLO

# la coincidencia es POR PREFIJO, no por igualdad: MIMIC usa
# codigos mas especificos que el mapeo (A047 -> A0471, A0472)
for p in prefijos:
    m = cod10.str.startswith(p)

# Tier B - acotar la ventana del comodin. Con re.DOTALL un .*
# atravesaba la nota entera y unia parrafos sin relacion.
def acotar(patron, n=100):
    return patron.replace('.*', '.{0,' + str(n) + '}'')
```

El estrato A1 y A2 existe porque MIMIC no trae bandera de present-on-admission: sin ella, una neumonía puede ser el motivo de ingreso y no una infección causada por la atención.

DOS VÍAS DE ETIQUETADO

- **Tier A** 223 códigos CIE-10 y CIE-9 mapeados al Anexo 02. Estratificados en A1 causal y A2 condiciones.
- **Tier B** 35 patrones de texto con NegEx para descartar la negación.

Efecto medido de las dos correcciones	Antes	Después
Tier A · hospitalizaciones recuperadas	411	109,714 (267×)
Tier B · detecciones con el comodín acotado	258,671	93,922 (−63.7 %)

Preprocesamiento (2): representación del texto y particiones

fase4_v2_etiqueta_a1.py

```
def construir_vectorizador():
    # Palabra + CARACTER: los n-gramas de caracter dan robustez
    # ante abreviaturas y variantes del texto clinico.
    return FeatureUnion([
        ('palabra', TfidfVectorizer(max_features=60000,
                                   ngram_range=(1, 2))),
        ('caracter', TfidfVectorizer(analyzer='char_wb',
                                   ngram_range=(3, 5))))

# Division POR PACIENTE, nunca por nota:
gss = GroupShuffleSplit(n_splits=1, test_size=0.2, random_state=42)
tr, te = next(gss.split(txt, Y, groups=df['subject_id']))
assert not (set(p tr) & set(p te)), 'FUGA: pacientes compartidos'
```

Remuestrear notas en vez de pacientes viola la independencia y estrecha artificialmente los intervalos de confianza. Por eso el bootstrap agrupa por subject_id.


TRES DECISIONES DE PROTOCOLO

- Partición por paciente, con aserción explícita de no solape
- El vectorizador se ajusta solo con el entrenamiento
- Intervalos por bootstrap agrupado por paciente, no por nota

Curva de escalabilidad: cuánto texto necesita el modelo	F1-macro
Truncado a 120 caracteres	0.214
Truncado a 2,000 caracteres (≈ 512 tokens)	0.433
Texto completo	0.526

Truncar a 512 tokens cuesta ~18 % del F1-macro. Es la medición propia que sustenta la necesidad de un modelo de contexto largo.

Modelamiento: dos etapas, con derecho a abstenerse



Prueba de abstención ante texto sin contenido clínico

texto de entrada	margen	decision
-----	-----	-----
.	-2.284	se abstiene
ok	-1.180	se abstiene
Paciente estable, sin novedad.	-0.978	se abstiene
Routine follow up. Vitals stable.	-0.876	se abstiene
Abstiene en 6/6 casos triviales.		

Un detector sin clase negativa marca como positivo casi cualquier texto: no puede decir «aquí no hay nada».

Añadirle es lo que convierte un clasificador en un detector.

Evaluar la Etapa 2 sobre positivos de referencia supone un detector perfecto y sobreestima el rendimiento. La cascada se evalúa solo sobre pacientes que ninguna de las dos etapas vio.

Cómo se ejecutó: entorno y coste real

Todo corrió en una laptop, sin nube y sin coste. El entorno se creó aislado para no comprometer el intérprete del sistema.

Preparación del entorno

```
"C:\ProgramData\Anaconda3\python.exe" -m venv T:\MIMIC\.venv-gpu

T:\MIMIC\.venv-gpu\Scripts\python.exe -m pip install torch \
--index-url https://download.pytorch.org/whl/cu126
T:\MIMIC\.venv-gpu\Scripts\python.exe -m pip install transformers \
accelerate sentence-transformers scikit-learn pandas pyarrow
```

Proceso	Duración real
Ablación sobre el corpus completo (331,793 notas)	17 h 56 min
Bio_ClinicalBERT · ajuste fino ponderado (GPU)	3 h 57 min
BioBERT · ajuste fino (GPU)	2 h 55 min
Bio_ClinicalBERT · ajuste fino (GPU)	2 h 55 min
Etiqueta A1 y curva de escalabilidad	2 h 46 min
Validación cruzada 5-fold	1 h 55 min
Resto de experimentos de la fase 4	1 h 03 min
Los 4 modelos TF-IDF	1 min 46 s
TOTAL REGISTRADO	33 h 54 min

HP Victus 16 · 12 hilos · 15.6 GB RAM
NVIDIA GTX 1650, 4 GB (sin Tensor Cores)
Windows 11 · Python 3.13 · disco NVMe dedicado

EL CONTRASTE QUE IMPORTA

Los 3 transformers: 9 h 47 min → F1-macro 0.354

Los 4 TF-IDF: 1 min 46 s → F1-macro 0.459

333 veces más cómputo, para perder.

Cómo se ejecutó: comandos y salida real de consola

Nada de esto está reconstruido. Es la salida literal de los logs, tal como quedó en la bitácora del proyecto.

```
python fase3_v2_tier_a_corregido.py
```

```
[23:00:34] [+0:00:00] Mapeo: 223 codigos - A1 73 - A2 150
[23:23:06] [+0:22:31] 6,364,488 diagnosticos
[23:23:06] [+0:22:31] metodo ORIGINAL (con punto):      411
[23:23:06] [+0:22:31] metodo CORREGIDO (prefijo): 109,714

Hospitalizaciones, original :      411
Hospitalizaciones, corregido : 109,714  (266.9x)
A1 causal explicito : 18,989 notas
A2 condiciones      : 53,375 notas
```

```
python fase3_v2_reanudar.py
```

```
[17:07:11] Checkpoint: 260,000 notas (78.4%)
[17:16:14] 280,000/331,793 ( 84.4%) | ETA 0:23:28
[17:39:37] 331,793/331,793 (100.0%) | ETA 0:00:00

Variante LAXA (re.DOTALL) : 258,671 detecciones
Variante ACOTADA (100 car): 93,922 detecciones
Reduccion al acotar      : 164,749 (63.7%)

Total 0:32:26
```

La corrida completa se cayó al 78.4 %. Por eso existe fase3_v2_reanudar.py, que retoma desde el punto de control en lugar de repetir 18 horas.

La verificación que confirma el diagnóstico	Antes	Después	Variación
Patrones CON comodín .*	42,330	6,735	-84.1 %
Patrones SIN comodín	13,189	13,189	0.0 %

El hallazgo central: un AUC de 0.973 que era falso

MIMIC abarca 2008–2019 y la transición CIE-9 → CIE-10 ocurrió en 2015. El mapeo inicial solo tenía CIE-10, así que toda hospitalización anterior era negativa por construcción.

Versión del detector	Especificidad	AUC	VPP
Inicial — INVÁLIDA, no se cita	0.917	0.973	0.433
Reevaluada con emparejamiento	0.694	0.904	0.171
Final — siete modos corregidos	0.770	0.843	0.455

QUÉ APRENDIÓ EL MODELO

No aprendió a reconocer eventos adversos: aprendió a distinguir la plantilla documental de cada época.

El rasgo de mayor peso era palabra__rdwsd — un artefacto de cabecera de laboratorio, sin ningún contenido clínico.

Los siete modos de fallo, todos con efecto medido

- Corpus era solo el 9 % (dos LIMIT sin declarar)
- re.DOTALL cruzaba la nota entera
- Códigos CIE con punto frente a MIMIC sin punto
- Ausencia de clase negativa
- Confusor de época CIE-9 / CIE-10 ← el más grave
- 43 de 223 códigos eran reglas muertas (CIE-10 OMS ≠ CM)
- Bandas de priorización degeneradas con n pequeño

Lección para llevarse: un AUC alto puede sostenerse íntegramente en una señal espuria. El aporte de este trabajo no es una métrica, es la auditoría que la hizo creíble.

Resultados: la etapa de detección

Métrica	Valor	IC 95 % (agrupado por paciente)
Sensibilidad	0.7623	[0.7514, 0.7729]
Especificidad	0.7699	[0.7591, 0.7809]
AUC	0.8426	[0.8361, 0.8493]

```
Matriz de confusion:  
VP=5,761  FP=1,502  FN=1,796  VN=5,026  
VPP crudo en el test (balanceado) : 0.793  
VPP reajustado a prevalencia real : 0.455  <-- el operativo
```

EL VPP DEPENDE DE DÓNDE SE DESPLIEGUE

prevalencia 5 %	VPP 0.148
prevalencia 10 %	VPP 0.269
prevalencia 20.12 %	VPP 0.455 ← la real
prevalencia 35 %	VPP 0.641
prevalencia 50 %	VPP 0.768

El mismo modelo, de 0.15 a 0.77, sin cambiar una línea.

De cada 100 alertas, 45 son eventos reales. Revisar notas clínicas al azar encuentra 20. El sistema multiplica por 2.26 la eficiencia del revisor: opera como filtro de cribado, no como árbitro.

Resultados: el ranking de los siete modelos

Todos evaluados sobre la misma partición estratificada, semilla 42. Las cifras son comparables entre sí.

#	Modelo	Exactitud	F1-macro	Kappa	Tiempo
1	TF-IDF + LinearSVC (texto completo)	0.7149	0.4592	0.5443	48 s
2	TF-IDF + LinearSVC sin balanceo (texto completo)	0.7109	0.3909	0.5132	47 s
3	Bio_ClinicalBERT (fine-tuning, ponderado)	0.5429	0.3541	0.3252	4.0 h
4	TF-IDF + LinearSVC (truncado a 1150 car.)	0.5746	0.3301	0.3148	6 s
5	TF-IDF + LinearSVC sin balanceo (truncado a 1150 car.)	0.5890	0.2747	0.2951	5 s
6	Bio_ClinicalBERT (fine-tuning)	0.6072	0.2487	0.3438	2.9 h
7	BioBERT (fine-tuning)	0.5971	0.2097	0.3182	2.9 h

```
EFFECTO AISLADO DE LA VENTANA DE CONTEXTO
(misma arquitectura y datos; solo cambia cuanto texto ve)
exactitud  completo 0.715 -> truncado 0.575 (-19.6%)
f1_macro   completo 0.459 -> truncado 0.330 (-28.1%)
kappa      completo 0.544 -> truncado 0.315 (-42.2%)
```

La ventana de 256 tokens cubre solo el 9.0% del documento (mediana 3,148 tokens por nota clínica).

La hipótesis inicial se refutó: el transformer clínico no superó al modelo léxico. La fila 4 explica por qué — al truncar el TF-IDF a la ventana de BERT, cae igual. No es la arquitectura, es cuánto texto ve. La mejora es Clinical-Longformer.

Resultados: cascada y contraste con el juicio experto

Evaluación	F1-micro	F1-macro
Etapa 2 aislada (positivos de referencia)	0.7516	0.5126
CASCADA real (Etapa 1 → Etapa 2)	0.4926	0.3626

Caída al encadenar: -34.5 % en F1-micro. Reportar la clasificación aislada sobreestima el rendimiento operativo en torno a un tercio.

Contra el consenso experto	Valor	IC 95 %
Sensibilidad	0.9455	[0.852, 0.981]
Especificidad	0.5385	[0.291, 0.768]
VPP	0.8966	[0.792, 0.952]

n = 68 casos · kappa sistema-experto 0.531 · matriz VP=52 FP=6 FN=3 VN=7

Robustez: ¿depende de quién anote?	n	Sensibilidad	Especificidad	Kappa
Consenso de ambos evaluadores (principal)	68	0.9455	0.5385	0.5307
Evaluador B por separado	77	0.9032	0.4667	0.3896
ANÁLISIS AMPLIADO: los 163 casos anotados (152 útiles)	152	0.9138 [0.849, 0.953]	—*	—*

* En el análisis ampliado solo se lee la sensibilidad: el piloto se muestreó por estratos definidos por la salida del sistema, así que la especificidad y el kappa se reportan sobre el consenso.

La sensibilidad se sostiene sobre 0.90 con cualquiera de las referencias — y al juntar los 163 casos anotados el intervalo se estrecha a la mitad. Además: el 25 % de los casos que la codificación declara negativos son eventos reales para el experto — el subregistro, medido con datos propios.

Resultados: el modelo ya funciona en texto peruano real

Cuatro tareas sobre 6,336 casos reales del sistema peruano de reporte, con los códigos del Anexo 02 asignados por profesionales. Predicción out-of-fold: cada caso lo predice un modelo que no lo vio.

Tarea	Qué predice	Modelo	Clases	Exactitud	F1-macro
T1	Evento adverso frente a incidente	LogReg	2	0.862	0.858
T2	Naturaleza (Anexo 02)	LinearSVC	9	0.846	0.766
T3	Severidad (Anexo 03)	LogReg	4	0.726	0.602
T4	Código de evento específico	LinearSVC	41	0.761	0.659

Lo que el corpus español rescata

Naturaleza	En MIMIC	En español
Gestión de la organización	n=24 · F1 0.000	F1 0.853
Cuidado del paciente	F1 0.791	F1 0.923
Medicación	F1 0.679	F1 0.875

ENTREGABLE PARA REVISIÓN

Los 8,799 casos exportados a Excel con la codificación humana, la predicción del modelo y el semáforo de acierto. Los 2,870 errores quedan en su propia hoja, listos para revisión clínica.

T4 es nuevo: el código de evento específico nunca se había modelado. De las 154 categorías usadas, 41 tienen casos suficientes y cubren el 89 % del corpus.

Del texto a la decisión de gestión

La salida del canal de PLN alimenta la matriz de priorización vigente en EsSalud. Esto ya no es PLN: es el destino del trabajo.

Frecuencia
 $A \rightarrow B = (A/\Sigma a) \times 9$

Impacto
 $G = 0.40 \text{ estancia} + 0.20 \text{ complic.} + 0.15 \text{ sobrecostos} + 0.25 \text{ insatisf.}$

Índice
 $H = B \times G \rightarrow I = H/\Sigma h \rightarrow J = I \times 100$

Banda y responsable
P25 verde · P50 amarillo · P75 rojo

Banda	Acción de mejora	Responsable
Verde (≤ P25)	Mejora de actividades	Jefatura de servicio
Amarillo (P25–P75)	Mejora de procesos	Departamento
Rojo (> P75)	Proyecto de mejora	Dirección

UN DEFECTO CORREGIDO

Con menos de 8 eventos los percentiles se degeneran e invierten la prioridad: una úlcera de impacto alto salía verde. Ahora, con $n < 8$, se usa corte absoluto sobre G.

La matriz no es una propuesta del autor: la Directiva N.º 7-OGCyH-ESSALUD-2020 la cita textualmente en su artículo 5.13 como el instrumento vigente.

Conclusiones

1 Un modelo léxico bien construido superó al transformer clínico.

La hipótesis inicial se refutó y el resultado negativo se reporta como tal: TF-IDF + LinearSVC 0.459 frente a Bio_ClinicalBERT 0.354 de F1-macro.

2 La diferencia se explica por la ventana de contexto, no por la arquitectura.

Truncar el modelo léxico a los 256 tokens que ve BERT lo degrada un 28 % con los mismos datos. La vía de mejora es un modelo de secuencia larga.

3 El aporte principal es la auditoría de validez.

Siete modos de fallo del etiquetado, con el confusor de época como caso ejemplar: un AUC de 0.973 sostenido en una plantilla documental.

4 La evaluación en cascada corrige un optimismo de un tercio.

F1-micro 0.752 aislada frente a 0.493 extremo a extremo.

5 Contra juicio experto el sistema recupera el 94.5 % de los eventos.

Con especificidad 0.538: sirve como cribado, no como árbitro.

6 El modelo ya demostró funcionar en texto peruano real.

Cuatro tareas con etiqueta de oro sobre casos reales del sistema nacional de reporte, incluida por primera vez la predicción del código de evento específico del Anexo 02.

Limitaciones declaradas

Se declaran porque acotan el alcance de cada cifra. Ninguna se descubrió después: todas están medidas.

Estándar de plata	Las métricas sobre MIMIC miden acuerdo con códigos CIE, no con juicio clínico.
Reutilización del conjunto de prueba	A lo largo de las iteraciones del canal; sesgo optimista no cuantificado. El umbral no se ajustó.
Alcance de la validación experta	La muestra está restringida a eventos de infección; n = 78.
Cobertura de datos estructurados	Las tablas de UCI cubren solo el 19.7 % de las notas clínicas.
Independencia del anotador	El autor es a la vez desarrollador y anotador. Se mitiga con interfaz ciega, orden aleatorio, cronometraje auditable y un segundo evaluador.
Transferencia al español no demostrada	Hoy son dos canales paralelos: el corpus español se entrena desde cero, no se transfiere el modelo de MIMIC.

Recomendaciones

Corto plazo

- Sustituir la arquitectura por Clinical-Longformer (ventana 4,096): es la hipótesis que el experimento deja planteada
- Anotar el gold standard de 350 notas para medir validez clínica
- Ampliar la clase GRAVE del corpus español (23 casos, F1 0.148)

Mediano plazo

- Entrenar sobre notas clínicas peruanas con un encoder clínico en español (bsc-bio-ehr-es), previa autorización de datos
- Integrar el detector como cribado en la Oficina de Calidad, con el revisor humano decidiendo siempre
- Medir el coste-beneficio real: horas-revisor ahorradas frente a revisiones improductivas generadas

El sistema no sustituye al profesional de calidad: le dice a quién mirar primero. Con VPP 0.455, más de la mitad de las alertas son falsas — aceptable para un cribado, no para una decisión automática.

Referencias principales

El artículo completo cita 34 fuentes. Estas son las que sostienen las decisiones de diseño.

- [1] Johnson, A. et al. MIMIC-IV-Note: deidentified free-text clinical notes v2.2. PhysioNet.
- [2] Alsentzer, E. et al. Publicly Available Clinical BERT Embeddings. Clinical NLP Workshop, 2019.
- [3] Lee, J. et al. BioBERT: a pre-trained biomedical language representation model. Bioinformatics, 2020.
- [4] Li, Y. et al. Clinical-Longformer and Clinical-BigBird: Transformers for long clinical sequences. 2022.
- [5] Ratner, A. et al. Snorkel: rapid training data creation with weak supervision. VLDB, 2017.
- [6] Geirhos, R. et al. Shortcut learning in deep neural networks. Nature Machine Intelligence, 2020.
- [7] Zech, J. et al. Variable generalization performance of a deep learning model to detect pneumonia. PLOS Medicine, 2018.
- [8] Byrt, T., Bishop, J., Carlin, J. Bias, prevalence and kappa. Journal of Clinical Epidemiology, 1993.
- [9] de Vries, E. et al. The incidence and nature of in-hospital adverse events. BMJ Quality & Safety, 2008.
- [10] EsSalud. Directiva GG-ESSALUD-2021: registro, notificación y gestión de los ERSP. Anexos 02 y 03.

Código, resultados y artículo completo: github.com/carlosperez100/PLN_SP · carlosperez100.github.io/PLN_SP

De la notificación voluntaria a la detección sistemática

El aporte no es una métrica alta: es una métrica en la que se puede confiar.

Carlos Pérez Pérez

MIA-10 Procesamiento del Lenguaje Natural · Universidad Nacional de Ingeniería · 2026